

# Inhaltsverzeichnis

<b>1</b>	<b>Norm und Skalarprodukt</b>	<b>7</b>
1.1	Norm . . . . .	7
1.2	Skalarprodukt . . . . .	7
1.2.1	Vom Skalarprodukt induzierte Norm . . . . .	7
1.2.2	Cauchy-Schwarzche Ungleichung . . . . .	7
<b>2</b>	<b>Symmetrische, positiv definite Matrix</b>	<b>8</b>
2.1	Cholesky-Zerlegung . . . . .	8
2.2	[?] diagonaldominant und alle Diagonalelemente größer gleich 0 . . . . .	8
2.3	Eigenwerte . . . . .	8
2.4	Eigenvektor . . . . .	8
<b>3</b>	<b>Matrixnormen</b>	<b>9</b>
3.1	Natürliche Matrixnorm . . . . .	9
3.2	Verträglichkeit . . . . .	9
3.3	Zeilensummennorm . . . . .	9
3.4	Spaltensummennorm . . . . .	9
3.5	Spektralnorm . . . . .	10
<b>4</b>	<b>Spektralradius, Konditionszahl einer Matrix</b>	<b>11</b>
4.1	Spektralradius $\rho$ . . . . .	11
4.2	Konditionszahl einer Matrix A . . . . .	11
4.3	Sonderfall symmetrisch, positiv definite Matrix . . . . .	11
<b>5</b>	<b>Ähnlichkeitstransformation, Invarianz der Eigenwerte</b>	<b>12</b>
5.1	Reduktionsmethoden . . . . .	12
<b>6</b>	<b>Gleitkommazahlen, ...</b>	<b>13</b>
6.1	Gleitkommazahl (normalisiert) . . . . .	13
6.2	Gleitkommagitter . . . . .	13
6.3	Maschinengenauigkeit eps . . . . .	13
6.4	Rundungsfehler . . . . .	13
<b>7</b>	<b>Darstellung des Interpolationsfehlers</b>	<b>14</b>
7.1	Fehler I . . . . .	14
7.2	Fehler II . . . . .	14
<b>8</b>	<b>Konditionierung einer numerischen Aufgabe, Konditionszahlen <math>k_{i,j}</math></b>	<b>15</b>
8.1	numerische Aufgabe . . . . .	15

8.2	Konditionszahl (relativ)	15
<b>9</b>	<b>Stabilität eines Algorithmus</b>	<b>16</b>
9.1	stabiler Algorithmus	16
<b>10</b>	<b>Auslöschung</b>	<b>17</b>
<b>11</b>	<b>Horner-Schema*</b>	<b>18</b>
11.1	Code	18
11.2	Auswertung	18
<b>12</b>	<b>Interpolation und Approximation</b>	<b>19</b>
12.1	Grundproblem	19
12.2	Aufgabenstellung	19
12.3	Interpolation	19
12.4	Approximation	19
<b>13</b>	<b>Lagransche Interpolationsaufgabe</b>	<b>20</b>
13.1	Aufgabe	20
13.2	Eindeutigkeit + Existenz	20
13.3	Lagransche Basispolynome	20
13.4	Eigenschaften	20
13.5	Lagransche Darstellung	20
<b>14</b>	<b>Newtonsche Basispolynome...</b>	<b>21</b>
14.1	Newton-Polynome	21
14.1.1	Auswertung	21
14.1.2	Vorteil	21
14.2	Newtonsche Darstellung	21
14.3	Dividierte Differenzen*	21
<b>15</b>	<b>Nevillsche Darstellung</b>	<b>22</b>
15.1	Schema	22
15.2	Code	22
<b>16</b>	<b>Hermite-Interpolation</b>	<b>23</b>
16.1	Aufgabe	23
16.2	Existenz + Eindeutig	23
16.3	Fehler	23

<b>17 Extrapolation</b>	<b>24</b>
17.1 Richardson-Extrapolation . . . . .	24
17.2 Lagrange . . . . .	24
17.3 Neville . . . . .	24
17.4 Extrapolationsfehler . . . . .	24
<b>18 Spline-Interpolation</b>	<b>26</b>
18.1 Interpolationsnachteil . . . . .	26
18.2 Abhilfe . . . . .	26
18.3 Lineare Spline . . . . .	26
18.4 Kubischer Spline . . . . .	26
18.5 Existenz . . . . .	26
18.6 Approximationsfehler . . . . .	26
<b>19 Gauß-Approximation</b>	<b>27</b>
<b>20 Gram-Schmidt-Algorithmus</b>	<b>28</b>
20.1 Code . . . . .	28
<b>21 Interpolatorische Quadraturformeln</b>	<b>29</b>
21.1 Interpolatorische Quadratur Formel . . . . .	29
21.2 Ordnung . . . . .	29
21.3 Newton-Cotes-Formel* . . . . .	29
21.4 Abgeschlossene Formeln . . . . .	29
21.5 Offene Formeln . . . . .	30
21.6 Code . . . . .	30
21.7 Problem . . . . .	30
21.8 Abhilfe: Summierte Quadraturformeln *	30
21.8.1 Fehlerdarstellung . . . . .	30
<b>22 Gaußsche Quadraturformeln *</b>	<b>31</b>
22.1 Gewichtetes Skalarprodukt . . . . .	31
22.2 Gauß-Quadratur . . . . .	31
22.3 Wahl der Stützstellen . . . . .	31
22.4 Kongergenz der Gauß-Quadraturen . . . . .	31
22.5 Code . . . . .	31
<b>23 Störungssatz...</b>	<b>32</b>
23.1 Störungssatz . . . . .	32
23.2 gestörte Matrix . . . . .	32

<b>24 Lösung von Dreieckssystemen+Aufwand*</b>	<b>33</b>
24.1 Rückwärtseinsetzen . . . . .	33
24.2 Vorwärtseinsetzen . . . . .	33
24.3 Aufwand . . . . .	33
<b>25 Gaußsches Eliminationsverfahren...</b>	<b>34</b>
25.1 Gauß-Elimination . . . . .	34
25.2 Spaltenpivotisierung . . . . .	34
25.3 LR - Zerlegung . . . . .	34
25.4 Code . . . . .	34
<b>26 Symmetrisch positiv definite Systeme</b>	<b>35</b>
26.1 Cholesky-Zerlegung . . . . .	35
26.2 Aufwand . . . . .	35
26.3 Code . . . . .	35
<b>27 Least-Squares-Lösungen, Normalgleichung</b>	<b>36</b>
27.1 Least-Squares-Lösung . . . . .	36
27.2 Eindeutigkeit . . . . .	36
<b>28 QR-Zerlegung, ...</b>	<b>37</b>
28.1 QR-Zerlegung . . . . .	37
28.2 Least-Squares mit Vollrang . . . . .	37
28.3 Aufwand . . . . .	37
28.4 Code . . . . .	37
<b>29 Householder-Transformation, ...</b>	<b>38</b>
29.1 Householder Transformation . . . . .	38
29.2 Eigenschaften von Householder . . . . .	38
29.3 Householder-Verfahren . . . . .	38
29.4 Ergebnis . . . . .	38
<b>30 Intervallschachtelung/Bisektionsverfahren</b>	<b>39</b>
30.1 Intervallschachtelung/Bisektionsverfahren . . . . .	39
30.2 Eigenschaften . . . . .	39
30.3 Code . . . . .	39
<b>31 Konvergenz iterativer Methoden</b>	<b>40</b>
31.1 Konvergenzordnung . . . . .	40
31.2 Lineare Konvergenz . . . . .	40
31.3 Superlineare Konvergenz . . . . .	40
31.4 Quadratische Konvergenz . . . . .	40

<b>32 Newton Verfahren im <math>\mathbb{R}^n</math></b>	<b>41</b>
32.1 Code . . . . .	41
<b>33 Newton-Kantorisch</b>	<b>42</b>
33.1 Voraussetzungen . . . . .	42
33.2 Fehlerabschätzung . . . . .	42
<b>34 Sukzessive Approximation *</b>	<b>43</b>
34.1 Konvergenz . . . . .	43
34.2 Code . . . . .	43
<b>35 Newton-Verfahren für affin - lineares <math>f(x) = Ax - b</math></b>	<b>44</b>
35.1 Problem . . . . .	44
<b>36 Fixpunktiteration *, Konvergenzaussage</b>	<b>45</b>
36.1 Problem . . . . .	45
36.2 Aufspaltung . . . . .	45
36.3 Konvergenz . . . . .	45
36.4 Code . . . . .	45
<b>37 Jacobi *, Gauß-Seidel *, SOR *</b>	<b>46</b>
37.1 Jacobi-Verfahren . . . . .	46
37.2 Gauß-Seidel . . . . .	46
37.3 SOR . . . . .	46
37.4 Konvergenz . . . . .	46
37.5 Fehler verringern . . . . .	46
<b>38 Allgemeines Abstiegsverfahren</b>	<b>47</b>
38.1 Voraussetzung . . . . .	47
38.2 A-Skalarprodukt, A-Norm . . . . .	47
38.3 Abstiegsverfahren . . . . .	47
38.4 Gradient . . . . .	47
38.5 Schrittweite . . . . .	47
38.6 Iteration . . . . .	47
38.7 Code . . . . .	47
<b>39 Gradientenverfahren</b>	<b>48</b>
39.1 Iteration . . . . .	48
39.2 Konvergenz . . . . .	48
39.3 Lemma von Kantorich . . . . .	48
39.4 Fehlerabschätzung . . . . .	48

<b>40 CG-Verfahren</b>	<b>49</b>
40.1 Fehlerabschätzung . . . . .	49
<b>41 Vorkonditionierung</b>	<b>50</b>
<b>42 Satz von Gerschgorin</b>	<b>51</b>
<b>43 Stabilitätsatz</b>	<b>52</b>
<b>44 Potenzmethode *, inverse Iteration *</b>	<b>53</b>
44.1 Potenzmethode . . . . .	53
44.2 Rayleigh-Quotient . . . . .	53
44.3 Inverse Iteration . . . . .	53
<b>45 Hessenberg-Normalform</b>	<b>54</b>
45.1 Hessengerg-Matrix . . . . .	54
<b>46 QR-Verfahren</b>	<b>55</b>

# 1 Norm und Skalarprodukt

## 1.1 Norm

Definitheit:  $\|x\| = 0 \Rightarrow x = 0$

absolute Homogenität:  $\|\alpha x\| = |\alpha| * \|x\|$

Dreiecksungleichung:  $\|x + y\| \leq \|x\| + \|y\|$

## 1.2 Skalarprodukt

$$\left. \begin{aligned} \langle x + y, z \rangle &= \langle x, z \rangle + \langle y, z \rangle \\ \langle x, y + z \rangle &= \langle x, y \rangle + \langle x, z \rangle \\ \langle \lambda x, y \rangle &= \lambda \langle x, y \rangle \\ \langle x, \lambda y \rangle &= \lambda \langle x, y \rangle \end{aligned} \right\} \text{Linearität}$$
$$\langle x, y \rangle = \langle y, x \rangle$$

$$\left. \begin{aligned} \langle x, x \rangle &\geq 0 \\ \langle x, x \rangle &= 0 \Rightarrow x = 0 \end{aligned} \right\} \text{positivDefinitheit}$$

### 1.2.1 Vom Skalarprodukt induzierte Norm

$$\|x\| = \sqrt{\langle x, x \rangle}$$

### 1.2.2 Cauchy-Schwarzche Ungleichung

$$|\langle x, y \rangle| \leq \|x\| * \|y\|$$

## 2 Symmetrische, positiv definite Matrix

$$\begin{pmatrix} a & b \\ b & c \end{pmatrix} \begin{pmatrix} a & b & c \\ b & d & e \\ c & e & f \end{pmatrix} \begin{pmatrix} a & b & c & d \\ b & e & f & g \\ c & f & h & i \\ d & g & i & j \end{pmatrix}$$

Symmetrische Matrix

insbesondere: Diagonalmatrizen, Einheitsmatrizen

positiv definit:  $x^t A x > 0$  (beliebige Matrix)

alle EW  $> 0$  (symmetrische Matrix)

alle Haupt[TODO: ?]  $> 0$  (symmetrische Matrix)

$$\begin{pmatrix} a & b & c \\ b & d & e \\ c & e & f \end{pmatrix} \Rightarrow 3 \text{ Hauptminoren[?]} = \det(a), \det \begin{pmatrix} a & b \\ b & d \end{pmatrix}, \det \begin{pmatrix} a & b & c \\ b & d & e \\ c & e & f \end{pmatrix}$$

### 2.1 Cholesky-Zerlegung

$A = G G^t$  G unter der Matrix, invertierbar (symmetrische Matrix)

### 2.2 [?] diagonaldominant und alle Diagonalelemente größer gleich 0

(symmetrische Matrix)

### 2.3 Eigenwerte

$$\det(\lambda \text{ En} - A) = 0$$

### 2.4 Eigenvektor

$$f(v) = \lambda v$$



### 3 Matrixnormen

#### 3.1 Natürliche Matrixnorm

$$\begin{aligned}\|A\|_{\infty} &:= \max_{x \neq 0} \frac{\|Ax\|_{\infty}}{\|x\|_{\infty}} = \max_{\|x\|_{\infty}=1} \|Ax\|_{\infty} \\ \|A\| &= 0 \Rightarrow A = 0 \\ \|\lambda A\| &= |\lambda| * \|A\| \\ \|A + B\| &\leq \|A\| + \|B\| \\ \|A * B\| &\leq \|A\| * \|B\|\end{aligned}$$

#### 3.2 Verträglichkeit

$$\|Ax\| \leq \|A\| * \|x\|$$

#### 3.3 Zeilensummennorm

= natürliche Matrixnorm

$$\|A\|_{\infty} = \max_{\|x\|_{\infty}=1} \|Ax\|_{\infty} = \max_{i=1,\dots,m} \sum_{j=1}^n |a_{ij}|$$

$$A = \begin{pmatrix} 1 & -2 & -3 \\ 2 & 3 & -1 \end{pmatrix}$$

$$\begin{aligned}\|A\|_{\infty} &= \max\{|1| + |-2| + |-3|, |2| + |3| + |-1|\} \\ &= \max\{6, 6\} = 6\end{aligned}$$

#### 3.4 Spaltensummennorm

$$\|A\|_1 := \max_{x \neq 0} \frac{\|Ax\|_1}{\|x\|_1} = \max_{\|x\|_1=1} \|Ax\|_1 = \max_{j=1,\dots,n} \sum_{i=1}^m |a_{ij}|$$

$$A = \begin{pmatrix} 1 & -2 & -3 \\ 2 & 3 & -1 \end{pmatrix}$$

$$\begin{aligned}\|A\|_1 &= \max\{|1| + |2|, |-2| + |3|, |-3| + |-1|\} \\ &= \max\{3, 5, 4\} = 5\end{aligned}$$

$$\|A^t\|_1 = \|A\|_{\infty}$$

### 3.5 Spektralnorm

$$\begin{aligned}
 \|A\|_2 &:= \max_{\|x\|_2=1} \|Ax\|_2 \\
 &= \max_{x \neq 0} \frac{\|Ax\|_2}{\|x\|_2} \\
 &= \max_{\|x\|_2=1} \langle Ax, Ax \rangle \\
 &= \max_{\|x\|_2=1} \langle A^t Ax, x \rangle \\
 &= \max \sqrt{|\lambda|}, \lambda * \text{EW von } A^t A
 \end{aligned}$$

$$\begin{aligned}
 A &= \begin{pmatrix} 3 & 2 \\ -2 & 0 \end{pmatrix}, \quad A^t A = \begin{pmatrix} 13 & 6 \\ 6 & 4 \end{pmatrix} \quad \det(\mu E_n - A^t A) = 0 \Leftrightarrow \mu_{1,2} = 16, 1 \\
 \|A\|_2 &= \sqrt{\max(\mu_1, \mu_2)} = \sqrt{\mu_1} = \sqrt{16} = 4
 \end{aligned}$$

## 4 Spektralradius, Konditionszahl einer Matrix

### 4.1 Spektralradius $\rho$

$\varphi(A) = \max : 1 \leq i \leq n |\lambda_i(A)| = \text{spr}(A)$  der betragsmäßig größte Eigenwert von A

$\|A\| \geq |\lambda|$  (für jede Matrixnorm, die mit einer Vektornorm verträglich ist)

### 4.2 Konditionszahl einer Matrix A

$$\text{cond}(A) = \|A\| * \|A^{-1}\|$$

### 4.3 Sonderfall symmetrisch, positiv definite Matrix

$$\text{cond}(A) = \frac{\lambda_{\max}}{\lambda_{\min}}$$

## 5 Ähnlichkeitstransformation, Invarianz der Eigenwerte

$$y = Ax$$

$$\bar{x} = Cx, \bar{y} = Cy \quad (\det C \neq 0), C \in GL$$

$$y = Ax \Rightarrow C^{-1}\bar{y} = AC^{-1}\bar{x} \Rightarrow \bar{y} = CAC^{-1}\bar{x} \Rightarrow \bar{y}\bar{A}\bar{x}$$

$$\bar{A} = CAC^{-1} \Rightarrow \bar{A} \sim A$$

$\lambda$  EW,  $v$  EV zu  $A$

$$\Rightarrow Av = C^{-1}\bar{A}Cv = \lambda v$$

$\Rightarrow \bar{A}$  und  $A$  haben dieselben Eigenwerte, algebraisch und geometrische Vielfachen stimmen überein (Invarianz der Eigenwerte)

### 5.1 Reduktionsmethoden

$A$  durch Ähnlichkeitstransformationen

$$A = A^{(0)} = T_1^{-1}A^{-1}T_1 = Q \dots = T_i^{-1}A^{(i)}T_i = \dots$$

auf Form bringen, für welche EW und EV leicht zu berechnen sind (z.B. Jordan-Normalform)

## 6 Gleitkommazahlen, ...

### 6.1 Gleitkommazahl (normalisiert)

$$b \in \mathbb{N}, b \geq 2, x \in \mathbb{R}$$

$$x = \pm m * b^{\pm e}$$

$$\text{Mantisse: } m = m_1 b^{-1} + m_2 b^{-2} + \dots \in \mathbb{R}$$

$$\text{Exponent: } e = e_{s-1} b^{s-1} + \dots + e_0 b^0 \in \mathbb{N}$$

für  $x \neq 0$  eindeutig

### 6.2 Gleitkommagitter

$A = A(b, r, s)$  größte Darstellbare Zahl:  $(1 - b^{-r}) * b^{b^s-1}$

mit  $b$  als Basis,  $r$  als Mantissenlänge,  $s$  als Exponentenlänge

$$(b = 10) : 0,314 * 10^1 = 3,14$$

$$0,123 * 10^6 = 123.000$$

Beispiel: konvertiere von Basis 8 zu Basis 10:

$$x = (0,5731 * 10^5)_8 \in A(8, 5, 1)$$

$$x = (5 * 8^{-1} + 7 * 8^{-2} + 3 * 8^{-3} + 1 * 8^{-4}) * 8^5$$

$$x = 5 * 8^4 + 7 * 8^3 + 3 * 8^2 + 1 * 8^1 = 24.264 * 10^0$$

### 6.3 Maschienenengenauigkeit eps

$$eps = \frac{1}{2} b^{-r+1}, IEEE : eps = \frac{1}{2} * 2^{-52} \approx 10^{-16}$$

### 6.4 Rundungsfehler

$$\text{absolut : } |x - rd(x)| \leq \frac{1}{2} b^{-r} b^e$$

$$\text{relativ : } \left| \frac{x - rd(x)}{x} \right| \leq \frac{1}{2} b^{-r+1} = eps$$

## 7 Darstellung des Interpolationsfehlers

### 7.1 Fehler I

$f \in C^{n+1}[a, b]$ ,  $\forall x \in [a, b] \exists \xi_x \in (\overline{x_0, \dots, x_n, x})$ , wobei das Intervall das kleinst mögliche Intervall, das alle  $x_i$  enthält, s.d.

$$f(x) - p(x) = \frac{f^{(n+1)}(\xi_x)}{(n+1)!} \prod_{j=0}^n (x - x_j)$$

### 7.2 Fehler II

$f \in C^{n+1}[a, b]$ ,  $\forall x \in [a, b] \setminus \{x_0, \dots, x_n\}$  gilt :

$$f(x) - p(x) = f[x_0, \dots, x_n, x] \prod_{j=0}^n (x - x_j)$$

$$\text{mit } f[x_i, \dots, x_{i+k}] = y[x_i, \dots, x_{i+k}]$$

$$\text{und } f[x_0, \dots, x_n, x] = \int_0^1 \int_0^{t_1} \dots \int_0^{t_n} f^{n+1}(x_0 + t_1(x_1 - x_0) + \dots + t_n(x_n - x_{n-1} + t(x - x_n)) dt dt_n \dots dt_1$$

für  $x_0 = x_1 = \dots = x_n :$

$$f[x_0, \dots, x_n] = \frac{1}{n!} f^{(n)}(x_0)$$

$$\frac{f^{(n+1)}(\xi_x)}{(n+1)!} \prod_{j=0}^n (x - x_j) = f(x) - p(x) = f[x_0, \dots, x_n, x] \prod_{j=0}^n (x - x_j)$$

$$\Rightarrow f[x_0, \dots, x_n, x] = \frac{f^{(n+1)}(\xi_x)}{(n+1)!}$$

## 8 Konditionierung einer numerischen Aufgabe, Konditionszahlen $k_{i,j}$

### 8.1 numerische Aufgabe

$x_j \in \mathbb{R}$  mit  $f(x_1, \dots, x_m) \Rightarrow y_i = f_i(x_j)$   
fehlerhafte Eingangsgrößen  $x_i + \Delta y_i$   
 $|\Delta y_i|$  ist der absolute Fehler,  $|\frac{\Delta y_i}{y_i}|$  ist der relative Fehler

### 8.2 Konditionszahl (relativ)

$$k_{ij}(x) = \frac{\partial f_i}{\partial x_j}(x) \frac{\Delta x_j}{x_j}$$

$$\frac{\Delta y_i}{y_i} = \sum_{j=1}^m k_{ij}(x) \frac{\Delta x_j}{x_j}$$

$|k_{ij}(x)| \gg 1 \Rightarrow$  schlecht konditioniert

$|k_{ij}(x)| \ll 1 \Rightarrow$  gut konditioniert, ohne Fehlerverstärkung

$|k_{ij}(x)| > 1 \Rightarrow$  Fehlerverstärkung

$|k_{ij}(x)| < 1 \Rightarrow$  Fehlerdämpfung

## 9 Stabilität eines Algorithmus

### 9.1 stabiler Algorithmus

akkumulierte Fehler der Rechnung (Rundungsfehler, Auswertungsfehler, etc.) übersteigen den unvermeidbaren Problemfehler der Konditionierung der Aufgabe nicht. Aka Trotz Ungenauigkeiten bei den Eingabe Variablen erhalten wir fast sehr genaue Ergebnisse.



## 10 Auslöschung

Verlust von Genauigkeit bei der Subtraktion von Zahlen mit gleichem Vorzeichen

TODO: bei bedarf ein Beispiel

## 11 Horner-Schema\*

Das sogenannte "Horner-Schema"

$b_n = a_n$  ,  $k = n - 1, \dots, 0$   $b_k = a_k + \xi b_{k+1}$  liefert den Funktionswert  
 $p(\xi) = b_0$  des Polynoms  
 $p(x) = a_0 + x(\dots + x(a_{n-1} + a_n x)\dots)$

### 11.1 Code

```
def horner(Ac, Ax, n, x):
```

```
    y = 0.0
```

```
    for i in reversed range(n):
```

```
        y = y * (x - Ax[i]) + Ac[i]
```

```
    return y
```

Ac: Vektor mit Koeffizienten, ist ein np Array

Ax: Stützstellen, ist ein np Array

n: Anzahl der Stützstellen, ist ein int

x: Auswertungspunkt, ist ein double

Immer Horner-Schema zur Auswertung von Polynomen verwenden.

### 11.2 Auswertung

TODO: subsection

## 12 Interpolation und Approximation

### 12.1 Grundproblem

Darstellung und Auswertung von Funktionen

### 12.2 Aufgabenstellung

$f(x)$  nur auf diskreter Menge von Argumenten  $x_0, \dots, x_n$  bekannt und soll rekonstruiert werden

analytisch gegebene Funktion soll auf Reelwerte dargestellt werden, damit jederzeit Werte zu beliebigen  $x$  berechnet werden können.

Einfach konstruierte Funktionen in Klassen  $P$ :

Polynome:  $p(x) = a_0 + a_1x + a_2x^2 + \dots + a_nx^n$

rationale Funktion:  $r(x) = \frac{a_0 + a_1x + \dots + a_nx^n}{b_0 + b_1x + \dots + b_mx^m}$

trigonometrische Funktion:  $t(x) = \frac{1}{2}a_0 + \sum_{k=1}^n (a_k \cos(kx) + b_k \sin(kx))$

Exponentialsummen:  $e(x) = \sum_{k=1}^n a_k \exp(b_k x)$

### 12.3 Interpolation

Zuordnung von  $g \in P$  zu  $f$  durch Fixieren von Funktionswerten

$$g(x_i) = y_i = f(x_i), i = 0, \dots, n$$

### 12.4 Approximation

$g \in P$  beste Darstellung, z.B.

$$\max_{a \leq x \leq b} |f(x) - g(x)| \text{ minimal}$$

$$\left( \int_a^b |f(x) - g(x)|^2 dx \right)^{\frac{1}{2}} \text{ minimal}$$

## 13 Lagransche Interpolationsaufgabe

### 13.1 Aufgabe

Finde zu  $n + 1$  verschiedene Stützstellen/Knoten  $x_0, \dots, x_n \in \mathbb{R}$  und Werten  $y_0, \dots, y_n \in \mathbb{R}$  ein Polynom  $p \in P_n$  mit  $p(x_i) = y_i$

### 13.2 Eindeutigkeit + Existenz

Die Lagransche Interpolationsaufgabe ist eindeutig lösbar

TODO: bei bedarf Beweis rein kopieren den Ich nicht verstanden hab

### 13.3 Lagransche Basispolynome

$$L_i^{(n)}(x) = \prod_{j=0, j \neq i}^n \frac{x - x_j}{x_i - x_j} \in P_n, i = 0, \dots, n$$

### 13.4 Eigenschaften

$$\text{ortogonal: es gilt } L_i^{(n)}(x_k) = d_{ik} = \begin{cases} 1 & i = k \\ 0 & \text{sonst} \end{cases}$$

bilden Basis von  $P_n$

haben Grad  $n$

### 13.5 Lagransche Darstellung

$$p(x) = \sum_{i=0}^n y_i L_i^{(n)}(x) \in P_n \text{ mit } p(x_j) = y_j$$

Nachteil: Bei Hinzunahme von  $(x_{n+1}, y_{n+1})$  ändert sich das Basispolynom komplett

TODO: Beispiel

## 14 Newtonsche Basispolynome...

### 14.1 Newton-Polynome

$$N_0(x) = 1, N_i(x) = \prod_{j=0}^{i-1} (x - x_j) \text{ mit } p(x) = \sum_{i=0}^n a_i N_i(x)$$

#### 14.1.1 Auswertung

$$\begin{aligned} y_0 &= p(x_0) = a_0 \\ y_1 &= p(x_1) = a_0 + a_1 * (x_1 - x_0) \\ &\vdots \\ y_n &= p(x_n) = a_0 + a_1(x_1 - x_0) + \dots + a_n(x_n - x_0) * \dots * (x_n - x_{n-1}) \end{aligned}$$

#### 14.1.2 Vorteil

Bei Hinzunahme von  $(x_{n+1}, y_{n+1})$  muss nur eine neue Rechnung durchgeführt werden, und nicht das gesamte Polynom neu berechnet werden

TODO: Beispiel

### 14.2 Newtonsche Darstellung(stabile Variante)

$$p(x) = \sum_{i=0}^n y[x_0, \dots, x_i] N_i(x)$$

### 14.3 Dividierte Differenzen\*

$$y[x_i, \dots, x_{k+1}] = \frac{y[x_{i+1}, \dots, x_{k+1}] - y[x_i, \dots, x_{i+k-1}]}{x_{i+k} - x_i} \text{ mit } k = 1, \dots, j \text{ und } i = k - j$$

für beliebige  $[?] \sigma : 0, \dots, n \rightarrow 0, \dots, n$  gilt  $y[\tilde{x}_0, \dots, \tilde{x}_n] = y[x_0, \dots, x_n]$

## 15 Nevillsche Darstellung

$$p_{jj}(x) = y_j \quad j = 0, \dots, n \quad k = 1, \dots, j \quad i = k - j$$

$$p_{i,i+k}(x) = p_{i,i+k-1}(x) + (x - x_i) \frac{p_{i+1,i+k}(x) - p_{i,i+k-1}(x)}{x_{i+k} - x_i}$$

### 15.1 Schema

$x$	$k = 0$		$k = 2$	$\dots$	$k = n - 1$	$k = n$
$x_0$	$y_0$	$\longrightarrow$	$p_{0,1}$	$\dots$	$p_{0,n-1}$	$p_{0,n}$
$x_1$	$y_1$	$\longrightarrow$	$p_{1,2}$	$\dots$	$p_{1,n}$	
$\vdots$	$\vdots$	$\vdots$	$\ddots$			
$x_{n-1}$	$y_{n-1}$	$\longrightarrow$	$p_{n-1,n}$			
$x_n$	$y_n$					

TODO: add the diagonal arrows

Hinzunahme von  $(x_{n+1}, y_{n+1})$  ist problemlos

Auswertung von  $p_{0,n}(x)$  in  $\xi \neq x_i$  ohne vorherige Bestimmung der Koeffizienten der Newton-Darstellung ist einfach und Numerisch stabil möglich

### 15.2 Code

```
def divDiffs(xi, yi, x):
    n = len(xi)
    p = n * [0]
    for k in range(n):
        for i in range(n - k):
            if k == 0:
                p[i] = yi[i]
            else:
                p[i] = ((x - xi[i + k]) * p[i] + (xi[i] - x) * p[i + 1]) / (xi[i]
- xi[i + k])
    return p[0]
```

## 16 Hermite-Interpolation

### 16.1 Aufgabe

Gegeben :  $x_i \quad i = 0, \dots, m \quad \text{paarweise verschieden}$   
 $y_i^{(k)} \quad i = 0, \dots, m \quad k = 0, \dots, \mu_i (\mu_i \geq 0)$

Gesucht:  $p \in P_n, n = m + \sum_{i=0}^m \mu_i : p^{(k)}(x_i) = y_i^{(k)}$

$x_i$  sind  $(\mu_i + 1)$ -fache Stützstellen

$x_0 = -1, x_1 = 1, m = 1, y_0^{(0)} = 0, y_1^{(0)}, y_1^{([l?])} = 2$

$\Rightarrow \mu_0 = 0, \mu_1 = 1$

$\Rightarrow n = 1 + 0 + 1 = 2$

$\Rightarrow p(x) = x^2$

### 16.2 Existenz + Eindeutig

analog zur Lagrange-Interpolation

### 16.3 Fehler

$f \in C^{n+1}[a, b] : \forall x \in [a, b] \exists \xi_x \in (\overline{x_0, \dots, x_m, x}), \text{ s.d.}$

$$f(x) - p(x) = f[x_0, \dots, x_0, \dots, x_m, \dots, x_m, x] \prod_{i=0}^m (x - x_i)^{\mu_i + 1}$$

$$= \frac{1}{(n+1)!} f^{(n+1)}(\xi_x) \prod_{i=0}^m (x - x_i)^{\mu_i + 1}$$

## 17 Extrapolation zum Limes + Fehler

### 17.1 Richardson-Extrapolation

nicht direkt berechenbare Größe

$$a(0) = \lim_{k \rightarrow 0} a(k), \quad k \in \mathbb{R}_+$$

berechne  $a(k_i)$  für gewisse  $k_i$ ,  $i = 0, \dots, n$  und  $[?] p_n(0)$  des Interpolations Polynoms zu  $(h_i, a(h_i))$  als Schätzung für  $a(0)$

$$a(0) := \lim_{x \rightarrow 0^+} \frac{\cos(x)-1}{\sin(x)} \quad (= 0)$$

$$a(x) := \frac{\cos(x)-1}{\sin(x)}$$

Interpolation  $a(x)$  an Stützstellen  $k_i$  nahe bei 0:

$$k_0 = \frac{1}{8} \quad a(k_0) = -6,258151 * 10^{-2}$$

$$k_1 = \frac{1}{16} \quad a(k_1) = -3,126018 * 10^{-2}$$

$$k_2 = \frac{1}{32} \quad a(k_2) = -1,562627 * 10^{-2}$$

### 17.2 Lagrange

$$p_2(x) = a(k_0) \frac{(x-\frac{1}{16})(x-\frac{1}{32})}{(\frac{1}{8}-\frac{1}{16})(\frac{1}{8}-\frac{1}{32})} + a(k_1) \frac{(x-\frac{1}{8})(x-\frac{1}{32})}{(\frac{1}{16}-\frac{1}{8})(\frac{1}{16}-\frac{1}{32})} + a(k_2) \frac{(x-\frac{1}{8})(x-\frac{1}{16})}{(\frac{1}{32}-\frac{1}{8})(\frac{1}{32}-\frac{1}{16})}$$

$$\Rightarrow a(0) \sim p_2(0) = -1,02 * 10^{-5}$$

### 17.3 Neville

$$p_{i,i+k}(0) = p_{i,i+k-1}(0) + \frac{p_{i,i+k-1}(0) - p_{i+1,i+k}(0)}{\frac{x_{i+k}}{x_i} - 1}, \quad k = 1, 2$$

i	$x_i$	$p_{i,i}(0) = a(k_i)$	$p_{i,i+1}(0)$	$p_{i,i+2}(0)$
0	$x_0 = \frac{1}{8}$	$-6,258151 * 10^{-2}$	$6,115 * 10^{-5}$	$-1,02 * 10^{-5}$
1	$x_1 = \frac{1}{16}$	$-3,126018 * 10^{-2}$	$7,64 * 10^{-6}$	
2	$x_2 = \frac{1}{32}$	$-1,562627 * 10^{-2}$		

### 17.4 Extrapolationsfehler

$a(n)$  habe die Entwicklung:

$$a(h) = a_0 + \sum_{j=1}^n a_j h^{jq} + a_{n+1}(h) h^{(n+1)q} \quad \text{mit } q > 0, \text{ Koeffizienten } a_j$$

$$\text{und } a_{n+1}(h) = a_{n+1} + a(1[????])$$

$(h_k)_{k \in \mathbb{N}}$  erfülle:

$$0 \leq \frac{h_{k+1}}{h_k} \leq p < 1 \quad (\Rightarrow h_k \text{ positiv monoton fallend})$$

Dann gilt für  $p_1^{(k)} \in P_n$  (in  $h^q$ ) durch  $(h_k^q, a(h_k)), \dots, (h_{k+n}^q, a(h_{k+n}))$



$$a(0) - p_n^{(k)}(0) = O(h_k^{(n+1)q}) \quad (k \rightarrow \infty)$$

## 18 Spline-Interpolation

### 18.1 Interpolationsnachteil

Starke Oszillation von Polynomen höheren Grades

### 18.2 Abhilfe

Spline-Interpolation, d.h. stückweise polynomielle Interpolation mit  $(n - 1)$ -mal stetig diff.baren Knoten

### 18.3 Lineare Spline

alle Abschnitt-Splines sind lineare Funktionen

### 18.4 Kubischer Spline

$s_n : [a, b] \rightarrow \mathbb{R}$  kubischer Spline bezüglich  $a = x_0 < x_1 < \dots < x_n = b$ , wenn gilt

1.  $s_n \in C^2[a, b]$
2.  $S_n|_{I_i} \in P_3$ ,  $i = 1, \dots, n$   
natürlicher Spline:
3.  $s_n''(a) = s_n''(b) = 0$

### 18.5 Existenz

Der interpolierende kubische Spline existiert und ist eindeutig bestimmt durch zusammen Vorgabe von  $s_n''(a), s_n''(b)$

für natürlichen Spline  $s_n$  durch  $x_0, \dots, x_n, y_0, \dots, y_n$  gilt:

$$\int_a^b |s'(x)|^2 dx \leq \int_a^b |g''(x)|^2 dx$$

bezüglich  $g \in C^2[a, b]$  mit  $g(x_i) = y_i, i = 1, \dots, n$

### 18.6 Approximationsfehler

$f \in C^4[a, b], s_1''(a) = f''(a) \wedge s_n''(b) = f''(b)$ :

$$\max_{x \in [a, b]} |f(x) - s_n(x)| \leq \frac{1}{2} h^4 \max_{x \in [a, b]} |f^{(4)}(x)|$$

## 19 Gauß-Approximation

$$\langle f, g \rangle := \int_a^b f(t) \overline{g(t)} dt \quad \|f\| = \sqrt{\langle f, f \rangle}$$

$H$  Prähilbertraum,  $\delta \subset H$  endlich Dimensional

$\exists f \in H$  eindeutig bestimmte "beste Approximation"  $g \in S$

$$\|f - g\| = \min_{\varphi \in S} \|f - \varphi\|$$

bes. einfache Lösung, wenn  $\{\varphi_1, \dots, \varphi_n\}$  eine ONB ist, d.h.

$$(\varphi_i, \varphi_j) = \delta_{i,j} \Rightarrow \alpha_i = \langle f, \varphi_i \rangle \quad i = 1, \dots, n$$

$$\Rightarrow g = \sum_{i=1}^n \langle f, \varphi_i \rangle \varphi_i \text{ ist beste Approximation}$$

## 20 Gram-Schmidt-Algorithmus

$$w_1 := \frac{v_1}{\|v_1\|} \quad \tilde{w}_k := v_k - \sum_{i=1}^{k-1} \gamma \langle v_k, w_i \rangle w_i, \quad w_k := \frac{\tilde{w}_k}{\|\tilde{w}_k\|}$$

### 20.1 Code

```
n = size(v, 1)
k = size(v, 2)
u = np.zeros(n, k)
u[:, 1] = v[:, 1]/sqrt(v[:, 1] * v[:, 1])
for i in range(2, k):
    u[:, i] = v[:, i]
    for j in range(1, i - 1):
        u[:, i] = u[:, i] - (u[:, i] * u[:, j]) / (u[:, j] * u[:, j]) * u[:, j]
    u[:, i] = u[:, i] / sqrt(u[:, i] * u[:, i])
```

## 21 Interpolatorische Quadraturformeln

$$I(f) = \int_a^b f(x) dx \approx I^{(n)}(f) = \sum_{i=1}^n \alpha_i f(x_i)$$

Stützstellen  $a \leq a_0 < x_1 < \dots < x_n \leq b$  und Gewichte  $\alpha_i \in \mathbb{R}$

### 21.1 Interpolatorische Quadratur Formel

$$I^{(n)}(f) = \int_a^b p_n(x) dx = \sum_{i=0}^n f(x_i) \int_a^b L_i^{(n)}(x) dx$$

Lagrange:

$$I(f) - I^{(n)}(f) = \int_a^b f[x_0, \dots, x_n, x] \prod_{i=0}^n (x - x_i) dx$$

$$\int_a^b f(x) dx \approx \int_a^b p_0(x) dx = (b-a) * \sum_{i=0}^n w_i f(x_i)$$

$$w_i = \frac{1}{(b-a)} \int_a^b L_i(x) dx$$

### 21.2 Ordnung

$$I^{(n)} \text{ von der Ordnung } m \Leftrightarrow \forall p \in P_{m-1}$$

$$\int_a^b p(x) dx = I^{(n)}(p) \quad \text{exakt}$$

$\Rightarrow$  Interpolatorische Quadraturformel zu  $(n+1)$ -Stützstellen sind mindestens von der Ordnung  $n+1$

$\Rightarrow$  höchstens Ordnung  $2n+2$ , mindestens  $n+1$

### 21.3 Newton-Cotes-Formel\*

äquidistante Stützstellen

### 21.4 Abgeschlossene Formeln

$$H = \frac{b-a}{n}, x_i = a + iH, a = x_0, b = x_n$$

$$\text{Trapezregel: } I^{(1)}(f) = \frac{b-a}{2} [f(a) + f(b)]$$

$$\text{Simpsonregel: } I^{(2)}(f) = \frac{b-a}{6} [f(a) + 4f(\frac{a+b}{2}) + f(b)]$$

$$\text{3/8-Regel: } I^{(3)}(f) = \frac{b-a}{8} [f(a) + 3f(a+H) + 3f(b-H) + f(b)]$$

---

<sup>1</sup> $\alpha_i$

## 21.5 Offene Formeln

$$(H = \frac{b-a}{n+2}, x_i = a + (i+1)H, a < x_0, x_n < b)$$

$$I^{(0)}(f) = (b-a)f(\frac{a+b}{2}) \quad \text{Mittelpunktregel}$$

$$I^{(1)}(f) = \frac{(b-a)}{2}(f(a+H) + f(b-H))$$

$$I^{(2)}(f) = \frac{(b-a)}{3}(2f(a+H) - f(\frac{a+b}{2}) + 2f(b-H))$$

## 21.6 Code

## 21.7 Problem

negative Gewichte  $\alpha_i \Rightarrow$  Auslöschungsgefahr

Oszillationen des Lagrange Interpolanten (Runge-Phänomen)

$$\Rightarrow I^{(n)}(f) \xrightarrow{n \rightarrow \infty} I(f)$$

## 21.8 Abhilfe: Summierte Quadraturformeln \*

$$I - n^{(n)}(f) = \sum_{i=1}^{N-1} I_{[x_i, x_{i+1}]}^{(n)}(f) \quad h = \frac{b-a}{N}, x_i = a + iH$$

### 21.8.1 Fehlerdarstellung

$$I_{[x_i, x_{i+1}]}(f) - I_{[x_i, x_{i+1}]}^{(n)}(f) = w_n h^{n+2} f^{(m+1)}(\xi_i), \quad \xi_i \in [a, b]$$
$$m \geq n : I(f) - I_n^{(n)}(f) = w_n h^{(m+1)}(b-a) f^{(m+1)}(\xi)$$

## 22 Gaußsche Quadraturformeln \*

### 22.1 Gewichtetes Skalarprodukt

$$\langle f, g \rangle_\omega = \int_a^b f(x)g(x)\omega(x)dx, \quad \omega(x) \geq 0, x \in (a, b)$$

### 22.2 Gauß-Quadratur

∃! interpolierte Quadraturformel [?] (n + 1) paarweise verschiedene Stützstellen auf [-1, b] mit Ordnung 2n + 2. Stützstellen = Nullstellen

$$\alpha_i = \int_{-1}^1 \prod_{j=0, j \neq i}^n \left( \frac{x - \lambda_j}{\lambda_i - \lambda_j} \right)^2 dx > 0^2, \quad i = 0, \dots, n$$

$$f \in C^{2n+2}([-1, 1]) \text{ Restglied :}$$

$$R^{(n)} = \frac{f^{(2n+2)}(\xi)}{(2n+2)!} \int_{-1}^1 \prod_{j=0}^n (x - \lambda_j)^2 dx, \quad \xi \in (-1, 1)$$

### 22.3 Wahl der Stützstellen

Nullstellen  $\lambda_0, \dots, \lambda_n \in (-1, 1)$  des (n + 1)-sten Legendre-Polynomes  $L_{n+1} \in P_{n+1}$

### 22.4 Kongergenz der Gauß-Quadraturen

Sei  $I^{(n)}(f)$  die (n + 1) punktige [?] Gauß-Formel zu  $I(f) = \int_{-1}^1 f(x)dx \forall f \in C[-1, 1] : I^{(n)}(f) \xrightarrow{n \rightarrow \infty} I(f)$

### 22.5 Code

---

<sup>2</sup>Positivität der Gewichte

## 23 Störungssatz...

### 23.1 Störungssatz

$A \in \mathbb{K}^{n \times n}$  regulär mit  $\|\delta A\| \leq \frac{1}{\|A^{-1}\|}$ , dann gilt für die

### 23.2 gestörte Matrix

$\tilde{A} = A + \delta A$  ist regulär

Für den relativen Fehler der Lösung gilt mit Konditionszahl von A:

$$\text{cond}(A) = \|A\| * \|A^{-1}\|$$

die Ungleichung:

$$\frac{\|\delta x\|}{\|x\|} \leq \frac{\text{cond}(A)}{1 - \text{cond}(A) \frac{\|\delta A\|}{\|A\|}} \left[ \frac{\|\delta b\|}{\|b\|} + \frac{\|\delta A\|}{\|A\|} \right]$$



## 24 Lösung von Dreieckssystemen+Aufwand\*

### 24.1 Rückwärtseinsetzen

$$x_j = \begin{cases} \frac{b_n}{a_{nn}} & j = n \\ \frac{1}{a_{jj}}(b_j - \sum_{k=j+1}^n a_{jk}x_k) & j = n-1, \dots, 1 \end{cases}$$

### 24.2 Vorwärtseinsetzen

$$x_j = \begin{cases} \frac{b_n}{a_{nn}} & j = n \\ \frac{1}{a_{jj}}(b_j - \sum_{k=j+1}^n a_{jk}x_k) & j = 1, \dots, n-1 \end{cases}$$

### 24.3 Aufwand

$$\sum_{j=1}^n j = \frac{(n+1)n}{2} = \frac{n^2}{2} + O(n)$$

## 25 Gaußsches Eliminationsverfahren...

### 25.1 Gauß-Elimination

Umformen von  $Ax = b$  auf  $Rx = c$ ,  $R$  ist eine rechte obere Dreieck Matrix

### 25.2 Spaltenpivotisierung

$$|a_{r_k,k}^{(k-1)}| = \max_{j=k,\dots,n} |a_{jk}^{(k-1)}|$$

### 25.3 LR - Zerlegung

$$Ax = b$$

$$\begin{pmatrix} 2 & 1 & 7 \\ 8 & 8 & 33 \\ -4 & 10 & 4 \end{pmatrix} x = \begin{pmatrix} 15 \\ 73 \\ 12 \end{pmatrix} \xrightarrow[2*]{(-4)*} \begin{pmatrix} 8 & 8 & 33 \\ 2 & 1 & 7 \\ -4 & 10 & 4 \end{pmatrix} P_1 = \begin{pmatrix} 0 & 1 & 0 \\ 1 & 0 & 0 \\ 0 & 0 & 1 \end{pmatrix}$$

Eliminierung

$$\begin{pmatrix} 8 & 8 & 33 \\ 2 & 1 & 7 \\ -4 & 10 & 4 \end{pmatrix} L_1 = \begin{pmatrix} 1 & 0 & 0 \\ \frac{1}{4} & 1 & 0 \\ -\frac{1}{2} & 0 & 1 \end{pmatrix} \rightsquigarrow \begin{pmatrix} 8 & 8 & 33 \\ 0 & 4 & 5 \\ 0 & 28 & 41 \end{pmatrix} P_2 = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 0 & 1 \\ 0 & 1 & 0 \end{pmatrix}$$

$$\begin{pmatrix} 8 & 8 & 33 \\ 0 & 28 & 41 \\ 0 & 4 & 5 \end{pmatrix} L_2 = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & \frac{1}{7} & 1 \end{pmatrix} \rightsquigarrow \begin{pmatrix} 8 & 8 & 33 \\ 0 & 28 & 41 \\ 0 & 0 & 6 \end{pmatrix} = R$$

$$PA = LR \Rightarrow L_2 L_1 P_2 P_1 A = F \Rightarrow P_2 P_1 A = L_1^{-1} L_2^{-1} R, P_2 P_1 = P$$

$$\begin{pmatrix} 1 & 0 & 0 \\ 0 & 0 & 1 \\ 0 & 1 & 0 \end{pmatrix} \begin{pmatrix} 0 & 1 & 0 \\ 1 & 0 & 0 \\ 0 & 0 & 1 \end{pmatrix} = \begin{pmatrix} 0 & 0 & 1 \\ 1 & 0 & 0 \\ 0 & 1 & 0 \end{pmatrix}$$

$$L_2 L_1 = (\cdot \cdot \cdot), (L_2 L_1)^{-1} = L = ([\text{linkeunteredreiecksmatrix}])$$

$$Ax = b \Rightarrow LRx = Pb, Pb = \tilde{b}$$

$$\Rightarrow Ly = \tilde{b}, Rx = y$$

A regulär + diagonaldominant  $\Rightarrow A = LR$  kann ohne Pivot bezeichnet werden

### 25.4 Code

## 26 Symmetrisch positiv definite Systeme

### 26.1 Cholesky-Zerlegung

Jede symmetrische positiv definite Matrix A hat eine sogenannte Cholesky - Zerlegung:

$$A = LDL^t = \tilde{L}\tilde{L}^t, \quad \tilde{L} := LD^{\frac{1}{2}}$$

$$\begin{pmatrix} \tilde{l}_{1,1} & \dots & 0 \\ \vdots & \ddots & \vdots \\ \tilde{l}_{n,1} & \dots & \tilde{l}_{n,n} \end{pmatrix} \begin{pmatrix} \tilde{l}_{1,1} & \dots & \tilde{l}_{n,1} \\ \vdots & \ddots & \vdots \\ 0 & \dots & \tilde{l}_{n,n} \end{pmatrix} = \begin{pmatrix} a_{1,1} & \dots & a_{1,n} \\ \vdots & \ddots & \vdots \\ a_{n,1} & \dots & a_{n,n} \end{pmatrix}$$

$$i \geq j : a_{i,j} = \sum_{k=1}^j \tilde{l}_{i,k} \tilde{l}_{j,k} = \sum_{k=1}^{j-1} \tilde{l}_{i,k} \tilde{l}_{j,k} + \tilde{l}_{i,j} \tilde{l}_{j,j}$$

$$i = 1, \dots, n \quad \tilde{l}_{i,i} = \sqrt{a_{i,i} - \sum_{k=1}^{i-1} \tilde{l}_{i,k}^2}$$

$$j = i + 1, \dots, n \quad \tilde{l}_{i,j} = \frac{1}{\tilde{l}_{i,i}} (a_{i,j} - \sum_{k=1}^{i-1} \tilde{l}_{i,k} \tilde{l}_{j,k})$$

Dandmatrizen: Nullen nicht speichern/berechnen Diagonal-Dominante:  
keine Pivotisierung notwendig symmetrisch positiv definite: keine Pivotisierung notwendig

### 26.2 Aufwand

$$N_{Cholesky}(n) = \frac{n^3}{6} + O(n^2) \quad (\text{billiger als } A = LR)$$

### 26.3 Code

## 27 Least-Squares-Lösungen, Normalgleichung

$$A \in \mathbb{R}^{m \times n} Ax = b$$

keine Lösung,  $b \notin \text{im}(A)$

unendlich viele Lösungen  $\bar{x} + \delta x \Leftrightarrow A\bar{x} = b, \delta x \in \ker(A) \neq \{0\}$

### 27.1 Least-Squares-Lösung

Es existiert immer eine "Lösung"  $\bar{x} \in \mathbb{R}^n$  mit kleinsten Fehlerquadraten

### 27.2 Eindeutigkeit

$R(A) = n \Leftrightarrow \bar{x}$  eindeutig, jede weitere Lösung:  $\bar{x} + y, y \in \ker(A)$

$$\text{Gerade: } b = C + Dt \begin{pmatrix} x_1 \\ y_1 \end{pmatrix} \begin{pmatrix} x_2 \\ y_2 \end{pmatrix} \begin{pmatrix} x_3 \\ y_3 \end{pmatrix}$$

$$\Rightarrow C + x_1 D = y_1$$

$$C + x_2 D = y_2$$

$$C + x_3 D = y_3$$

$$\Rightarrow A = \begin{bmatrix} 1 & x_1 \\ 1 & x_2 \\ 1 & x_3 \end{bmatrix} x = \begin{bmatrix} C \\ D \end{bmatrix} b = \begin{bmatrix} y_1 \\ y_2 \\ y_3 \end{bmatrix}$$

$$1. C = A^t A = \begin{bmatrix} \end{bmatrix}, b' = A^t b = \begin{bmatrix} \end{bmatrix}$$

$$2. \text{Cholesky Zerlegung: } G^t G = C \Rightarrow G = \begin{bmatrix} \end{bmatrix}$$

$$3. G^t y = b' \Rightarrow y = \begin{bmatrix} \end{bmatrix}, Gx = y \Rightarrow x = \begin{bmatrix} a_1 \\ a_2 \end{bmatrix}$$

$$\Rightarrow \text{Gerade: } b = a_1 + a_2 t$$

$$\text{Alternativ: } Q^t A = R = \begin{bmatrix} a_1 \\ a_2 \end{bmatrix}, Gx = y \Rightarrow x = \begin{bmatrix} a_1 \\ a_2 \end{bmatrix}$$

$$R_1 x = \tilde{b}_1 \Rightarrow D = a_1, C = A_2$$

## 28 QR-Zerlegung, ...

### 28.1 QR-Zerlegung

$A \in \mathbb{K}^{m \times n}$ ,  $\text{Rang}(A) = n \leq m$

$\exists$  eindeutig bestimmte Matrix  $Q \in \mathbb{K}^{m \times n}$   $Q^t Q = E_n$  (für  $\mathbb{K} = \mathbb{R}$ )  
 $\overline{Q}^t Q = E_n$  (für  $\mathbb{K} = \mathbb{C}$ )

und eindeutig bestimmte obere Dreiecks Matrix  $R \in \mathbb{K}^{n \times n}$   $r_{i,i} < 0$  reell,  
s.d.

$A = QR$   $Q$  orthonormale Matrix ( $m = n$  unitär)  $Q^t = Q^{-1}$

$u := v + \mathfrak{S} \|v\| * e_n$

$\mathfrak{S}$

$\begin{cases} -1 & v_1 < 0 \\ 1 & v_1 \geq 0 \end{cases}$  Householder Matrix  $H = E_n - 2 \frac{uu^t}{u^t u}$

### 28.2 Least-Squares mit Vollrang

$A = Q_1 R = (Q_1 | Q_2) \begin{pmatrix} R \\ 0 \end{pmatrix}$ ,  $Q = (Q_1 | Q_2) \in \mathbb{R}^{m \times n}$

$Rx = Q^t b$   $R = \begin{pmatrix} R \\ 0 \end{pmatrix} \in \mathbb{R}^{m \times n}$

$\text{Rang}(A) = n$

$\|Ax - b\|_2^2 = \|Rx - Q_1^t b\|_2^2 + \|Q_2^t b\|_2^2$  minimal für  $x = R^{-1} Q_1^t b$

### 28.3 Aufwand

Doppelter Aufwand für QR wie für LR

$N_{QR}(n) = \frac{2}{3}n^3 + O(n^2)$

### 28.4 Code

## 29 Householder-Transformation, ...

### 29.1 Householder Transformation

$v \in \mathbb{K}, \|v\|_2 = 1$

$$H = E_n - 2 \frac{vv^t}{v^t v}$$

Spiegelung eines Vektors an einer Hyperebene durch Null im euklidischen Raum  $H_{\vec{x}} = x - 2vv^t x$

$$v\bar{v}^t = \begin{pmatrix} v_1\bar{v}_1 & \dots & v_1\bar{v}_n \\ \vdots & \ddots & \vdots \\ v_n\bar{v}_1 & \dots & v_n\bar{v}_n \end{pmatrix}$$

TODO: skizze

### 29.2 Eigenschaften von Householder

Symmetrisch:  $H = H^t$

Orthogonal:  $H^t H = E_n$

Involutorisch:  $H^2 = E_n$

EW: -1 einfach, 1 (n - 1)-fach

Mantisse-Vektor-Multiplikationen mit Householder sind schnell berechenbar

### 29.3 Householder-Verfahren

Gruppe numerischer Verfahren zur Bestimmung von Nullstellen einer skalaren, reellen Funktion

Zur Berechnung der QR-Zerlegung

$S_t A^{(t-1)} = A^{(t)}$ ,  $S_t$  ist Householder-Transformation

### 29.4 Ergebnis

QR-Zerlegung von A (aber nichteindeutig!)

## 30 Intervallschachtelung/Bisektionsverfahren

### 30.1 Intervallschachtelung/Bisektionsverfahren

n = 1

Erzeugen einer konvergenten Folge von Intervallschachtelungen

$a_0, b_0 \in [a, b]$  mit  $f(a_0)f(b_0) < 0$

Konvergenz:  $a_k \leq a_{k+1} \leq b_{k+1} \leq b_k$

$|b_{k+1} - a_{k+1}| = \frac{1}{2}|b_k - a_k| = 2^{-k-1}|b_0 - a_0|$

### 30.2 Eigenschaften

sehr stabil, langsam, Erweiterung für  $x \in \mathbb{R}^n \vee x \in \mathbb{C}$  nicht möglich

### 30.3 Code

for k = 0, 1, ... do:

$x[k] = 0.5(a[k] + b[k])$

    if  $f(a[k])f(x[k]) \leq 0$ :

$a[k+1] = a[k]$

$b[k+1] = x[k]$

    else:

$a[k+1] = x[k]$

$b[k+1] = b[k]$

    if  $\text{abs}(b[k+1] - a[k+1]) \leq \text{TOL} \cdot \text{abs}(a[k+1])$ :

        Ende Lösung:  $0.5(b[k+1] + a[k+1])$

## 31 Konvergenz iterativer Methoden

### 31.1 Konvergenzordnung

$$\alpha > 1$$

$$|x_{k+1} - x_*| \leq C|x_k - x_*|^\alpha \quad k = 0, 1, \dots$$

### 31.2 Lineare Konvergenz

$$\alpha = 1 \Rightarrow \text{ClineareKontraktionsrate}$$

### 31.3 Superlineare Konvergenz

$$|x_{k+1} - x_k| \leq C_k|x_k - x_*| \quad \text{mit } C_k \rightarrow 0$$

### 31.4 Quadratische Konvergenz

$$|x_{k+1} - x_*| \leq C|x_k - x_*|^2 \quad \text{also } \alpha = 2$$

Konvergenz der Ordnung  $\alpha$  (quadratische Konvergenz, kubische, etc.)  $\Rightarrow$   
superlineare Konvergenz  $\Rightarrow$  lineare Konvergenz



## 32 Newton Verfahren im $\mathbb{R}^n$

$$x_{k+1} = x_k - j_f(x_k)^{-1} f(x_k)$$

$$j_f(x_k)^{-1} = \frac{1}{\det(j_f)} * j_f^*, \quad j_f^* = \begin{pmatrix} a_{2,2} & -a_{1,2} \\ -a_{2,1} & a_{1,1} \end{pmatrix}$$

guter Startwert:            superlineare Konvergenz

schlechter Startwert<sup>3</sup>:   lineare Konvergenz

### 32.1 Code

## 33 Newton-Kantorisch

### 33.1 Voraussetzungen

$f : x \in \mathbb{R}^n \rightarrow \mathbb{R}^n$  mit  $f'$  L-stetig, d.h.

1.  $\|j_f(x) - j_f(y)\| \leq L\|x - y\|$
2.  $\|j_f^{-1}(x)\| \leq \beta$
3.  $x_0 \in D_f(x)$
4.  $q := \frac{1}{2}\alpha\beta L$  mit  $\alpha = \|j_f^{-1}(x_0)f(x_0)\|$  auf der Niveaumenge  $D(x) = \{y \in D \mid \|f(y)\| \leq \|x\|\}$   
 $\Rightarrow$  Dann konvergiert  $(x_k)$  quadratisch gegen Nullstelle  $z \in D$  von  $f$

### 33.2 Fehlerabschätzung

$$\|x_k - x_*\| \leq \frac{\alpha}{1-q} q^{(2^k-1)}, \quad k \geq 1$$

## 34 Sukzessive Approximation \*

$x_{t+1} = x_t + C^{-1}f(x_t)$       C reguläre Matrix  $\in \mathbb{R}^{n \times n}$   
 $x_t \xrightarrow[t \rightarrow \infty]{z} \Rightarrow z = z + C^{-1}f(z)$  bzw  $f(z) = 0 \Rightarrow z$  Fixpunkt der Abbildung  
 $g(x) := x + C^{-1}f(x)$

### 34.1 Konvergenz

$g : G \rightarrow G$  Kontraktion,  $\exists$  Fixpunkt  $z \in G$  von  $g$ ,  $q$  Kontraktionskonstante

$$\|x_t - z\| \leq \frac{q}{1-q} \|x_t - x_{t-1}\| \leq \frac{q^t}{1-q} \|x_1 - x_0\|$$

### 34.2 Code

## **35   Newton-Verfahren für affin - lineares $f(x)$ = $Ax - b$**

### **35.1   Problem**

Direkte Methoden  $\rightarrow$  großen Speicheraufwand für große  $n$

## 36 Fixpunktiteration \*, Konvergenzaussage

### 36.1 Problem

für sehr große n ist Gauß-Elimination zu speicherintensiv

$$Ax = b \Leftrightarrow a_{j,j} * x_j + \sum_{k=1}^n a_{j,k} x_k = b_j$$

### 36.2 Aufspaltung

$$A = D + L + R$$

$$D = \begin{pmatrix} a_{1,1} & & 0 \\ & \ddots & \\ 0 & & a_{n,n} \end{pmatrix} \quad L = \begin{pmatrix} 0 & \dots & \dots & 0 \\ a_{2,1} & \ddots & \dots & \vdots \\ \vdots & \ddots & \dots & \vdots \\ a_{n,1} & \dots & a_{n,n-1} & 0 \end{pmatrix} \quad R = \begin{pmatrix} 0 & a_{1,2} & \dots & a_{1,n} \\ \vdots & \ddots & \dots & \vdots \\ \vdots & \ddots & \dots & a_{n-1,n} \\ 0 & \dots & \dots & 0 \end{pmatrix}$$

$$x_t = Bx_{t-1} + c, \quad B \text{ Iterationsmatrix}$$

### 36.3 Konvergenz

$$x_t \xrightarrow[t \rightarrow \infty]{x} \Rightarrow x = Bx + c$$

$$x_t \rightarrow x \Leftrightarrow \text{spr}(B) = \max |\lambda| \text{ von } B < 1$$

Asymptotisches Konvergenzverhalten:

$$\sup_{x_0 \in \mathbb{R}^n} \limsup_{t \rightarrow \infty} \left( \frac{\|x_t - x\|}{\|x_0 - x\|} \right)^{\frac{1}{t}} = \text{spr}(B)$$

### 36.4 Code

## 37 Jacobi \*, Gauß-Seidel \*, SOR \*

### 37.1 Jacobi-Verfahren

$$B = J = -D^{-1}(L + R) \text{ mit } A = D + L + R$$

### 37.2 Gauß-Seidel

$$B = H_1 = -(D + L)^{-1}R$$

### 37.3 SOR

$$H_w = (D + wL)^{-1}((1 - w)D - wR)$$

(für  $w = 1$ : Gauß-Seidel)

### 37.4 Konvergenz

für positiv definit symmetrische Matrizen:

(I) starke/strikte Diagonaldominanz  $\Rightarrow$  J/G-S konvergiert

(II) diagonaldominanz + irreduzibel<sup>4</sup>  $\Rightarrow$  J/G-S konvergiert

(III) Beachte EW von:  $J = -D^{-1}(L + R)$  J konvergiert für  $\text{spr}(J) < 1$   
 $H = -(D + L)^{-1}R$  G-S konvergiert für  $\text{spr}(H) < 1$

### 37.5 Fehler verringern

Wie viele Iterationsschritte  $t$  bis Fehler um  $10^k$  verbessert ist?

$$t \geq -\frac{k}{\log_{10} f} \quad f = \text{spr}(B)$$

---

<sup>4</sup>Knotenmodell

## 38 Allgemeines Abstiegsverfahren

### 38.1 Voraussetzung

A symmetrisch positiv definiert

$$\Rightarrow \langle Ax, y \rangle = \langle x, Ay \rangle, \langle Ax, x \rangle > 0$$

### 38.2 A-Skalarprodukt, A-Norm

$$\langle x, y \rangle_A = \langle x, Ay \rangle, \|x\|_A = \sqrt{\langle Ax, x \rangle}$$

A hat nur reelle EW

$$\lambda_{\min} := \lambda_1 \leq \dots \leq \lambda_n =: \lambda_{\max} \Rightarrow \text{spr}(A) = \lambda_{\max}, \text{cond}_2(A) = \frac{\lambda_{\max}}{\lambda_{\min}}$$

### 38.3 Abstiegsverfahren

Iteratives Verfahren, um lokales Minimum einer Funktion zu finden.

In jedem Schritt entlang einer bestimmten Richtung minimieren

### 38.4 Gradient

$$g_t = Ax_t - b, \text{ Abstiegsrichtung } r_t$$

### 38.5 Schrittweite

$$\alpha_t = -\frac{\langle g_t, r_t \rangle}{\langle Ar_t, r_t \rangle}$$

### 38.6 Iteration

$$x_{t+1} = x_t + \alpha_t r_t$$

$\Rightarrow$  Minimierung von Q minimiert

Defektnorm  $\|A y - b\|_{A^{-1}}$  und Fehlnorm  $\|y - x\|_A$

### 38.7 Code

## 39 Gradientenverfahren

Richtung des steilsten Abstiegs

$$r_t = -\text{grad } Q(x_t) = -g_t$$

### 39.1 Iteration

$$x_0 \in \mathbb{R}^n, g_0 = Ax_0 - b, t \geq 0$$

$$\alpha_t = \frac{\|g_t\|^2}{\langle Ag_t, g_t \rangle}$$

$$x_{t+1} = x_t - \alpha_t g_t$$

$$g_{t+1} = g_t - \alpha_t Ag_t$$

$$\langle Ag_t, g_t \rangle = 0 \Rightarrow g_t = 0 \Rightarrow Ax_t = b$$

### 39.2 Konvergenz

A positiv definit symmetrisch  $\Rightarrow$  Gradientenverfahren konvergiert  $\forall x_0$  gegen  
 $Ax = b$

### 39.3 Lemma von Kantorich

$$4 \frac{\lambda_{\min} \lambda_{\max}}{(\lambda_{\min} + \lambda_{\max})^2} \leq \frac{\| \cdot \|^4}{\langle y, Ay \rangle \langle y, A^{-1}y \rangle}$$

### 39.4 Fehlerabschätzung

$$\|x_t - x\|_A \leq \left(\frac{1-K^{-1}}{1+K^{-1}}\right)^t \|x_0 - x\|_a, \quad t \in \mathbb{N}$$

$\Rightarrow$  Lagrangsche Konvergenz für  $\text{cond}_2(A) \gg 1$



## 40 CG-Verfahren

Effiziente numerische Methode zur Lösung großen LGS mit symmetrisch positiv definitem A

Liefert nach spätestens m Schritten die exakte Lösung für  $A \in \mathbb{R}^{m \times m}$  für exakte Arithmetik)

Fehler fällt monoton

Wähle Abstiegsrichtung  $d_t$  mit  $\langle d_t, d_j \rangle = 0 \forall i \neq j$

$$x_t = x_0 + \sum_{i=0}^{t-1} \alpha_i d_i$$

$$\Rightarrow x_{t+1} = x_t + \alpha_t d_t$$

$$\alpha_t = \frac{\|g_t\|^2}{\langle d_t, A d_t \rangle} \quad \beta_t = \frac{\|g_{t+1}\|^2}{\|g_t\|^2}$$

$$x_{t+1} = x_t + \alpha_t d_t$$

$$g_{t+1} = g_t + \alpha_t A d_t$$

$$d_{t+1} = -g_{t+1} + \beta_t d_t$$

$$d_0 = g_0 = b - A x_0$$

### 40.1 Fehlerabschätzung

$$\|x_t - x\|_A \leq 2 \left( \frac{1 - \frac{1}{\sqrt{K}}}{1 + \frac{1}{\sqrt{K}}} \right)^t \|x_0 - x\|_A \quad t \in \mathbb{N}$$

$$K = \text{cond}_2(A) = \frac{\lambda_{\max}}{\lambda_{\min}}$$

Reduzierung des Anfangsfehlers:  $\max_t(\epsilon) \leq \frac{1}{2} \sqrt{K} \ln\left(\frac{2}{\epsilon}\right) + 1 \text{ Schritte}$

$\Rightarrow$  CG konvergiert schneller als Gradientenverfahren

schneller, je näher  $\text{cond}_2(A)$  bei 1 liegt, da  $\text{cond}_2(A) = \frac{\lambda_{\max}}{\lambda_{\min}}$

aber, falls  $\lambda_{\max} \gg \lambda_{\min} \Rightarrow$  CG verfahren langsam

Lösung: Vorkonditionierung

## 41 Vorkonditionierung

$Ax = b$  umformen in  $\tilde{A}\tilde{x} = \tilde{b}$  mit besser konditioniertem  $\tilde{A}$  symmetrisch positiv definit,  $K$  regulär:  $C = KK^t$

$$Ax = b \Leftrightarrow K^{-1}A(K^t)^{-1}K^t x = K^{-1}b$$

Dann CG anwenden auf  $\tilde{A}\tilde{x} = \tilde{b}$

Wähle  $C$  so, dass  $\text{cond}_2(\tilde{A}) \ll \text{cond}_2(A)$

$$\text{Startwerte: } \tilde{x}_0 \in \mathbb{R}^n \quad \tilde{d}_0 = -\tilde{g}_0 = \tilde{b} - \tilde{A}\tilde{x}_0$$

$$g_0 = A x_0 - b$$

$$C_{\rho_{t+1}} = g_{t+1} \quad C_{\rho_0} = g_0 \quad d_0 = -\rho_0$$

---

<sup>5</sup> $\tilde{A}$

<sup>6</sup> $\tilde{x}$

<sup>7</sup> $\tilde{b}$

## 42 Satz von Gerschgorin

Alle EW von  $A$  in  $\mathbb{K}^{n \times n}$  liegen in der Vereinigung der sogenannten Gerschgorin-Kreise

$$K_j = \{ \zeta \in \mathbb{C} \mid |\zeta - a_{j,j}| \leq \sum_{k=1, k \neq j}^n |a_{j,k}| \}$$

$$U = \bigcup_{i=1}^m K_{j,i}, \quad V = \bigcup_{j=1}^n K_j \setminus U$$

Sind  $U \cap V = \emptyset \Rightarrow m$  EW in  $U$ ,  $n - m$  in  $V$

## 43 Stabilitätsatz

$A \in \mathbb{K}^{n \times n}$  mit  $n$  linear unabhängige EV,  $B \in \mathbb{K}^{n \times n}$   
 $\Rightarrow \forall \lambda_B$  EW von  $B \exists \lambda_A$  EW von  $A$ :  
 $|\lambda_A - \lambda_B| \leq \text{cond}_2(W) \|A - B\|_2$   
 $W = (w_1, \dots, w_n) \in \mathbb{K}^{n \times n}$  EV von  $A$

## 44 Potenzmethode \*, inverse Iteration \*

Verfahren, um einen (nicht alle) EW zu finden

### 44.1 Potenzmethode

$$\zeta \in \mathbb{C}^n \quad \|\zeta_0\| = 0 \quad t \geq 1$$

$$\tilde{\zeta}_t = A_{\zeta_{t-1}} \quad \zeta_t = \frac{\tilde{\zeta}_t}{\|\tilde{\zeta}_t\|} \quad \lambda_t := \frac{\tilde{\zeta}_t^t}{\zeta_t^t} \quad \zeta_t^t \neq 0$$

### 44.2 Rayleigh-Quotient

A diagonalisierbar mit  $|\lambda_n| > |\lambda_i|$

$$\lambda_t = \frac{\langle \zeta_t, A \zeta_t \rangle}{\langle \zeta_t, \zeta_t \rangle}$$

### 44.3 Inverse Iteration

A quadratisch  $x_0 \in \mathbb{R}^n$ ,  $\theta \in \mathbb{R}$  s.d.:

1.  $q_k = \frac{x_{k-1}}{\|x_{k-1}\|}$
  2. Löse  $(A - \theta E)x_k = q_k$  ( $A - \theta E$ ) regulär
- EW ergibt sich mit Rayleigh-Quadratur:  $\lambda_k = \frac{x_k^t A x_k}{x_k^t x_k}$

## 45 Hessenberg-Normalform

$\forall A \in \mathbb{R}^{n \times n} \exists$  Folge  $T_i$  von Householder-Matrizen, so dass:

$i = 1, \dots, n - 2$

$TAT^t$  Hessenberg-Matrix ist

### 45.1 Hessengerg-Matrix

$H \in \mathbb{C}^{n \times n}$  mit  $h_{i,j} = 0 \forall i > j + 1$

$$H = \begin{pmatrix} h_{1,1} & \dots & \dots & \dots & h_{1,n} \\ h_{2,1} & \ddots & \ddots & \ddots & \vdots \\ 0 & \ddots & \ddots & \ddots & \vdots \\ \vdots & \ddots & \ddots & \ddots & \vdots \\ 0 & \dots & 0 & h_{n,n-1} & h_{n,n} \end{pmatrix}$$

alle Einträge unterhalb der ersten Nebendiagonalen sind 0 (obere H-Matrix) analog definiert man untere H-Matrix

sowohl obere als auch untere H-Matrix

$\Rightarrow$  Tridiagonalmatrix

## 46 QR-Verfahren

Berechnung aller EW einer quadratischen Matrix  $A_1 = A \in \mathbb{K}^{n \times n}$

$A_t = Q_t R_t \rightarrow A_{t+1} = R_t^* Q_t = Q_{t+1}^* R_{t+1} \rightarrow \cdots \rightarrow A_{t+n}$  Diagonalmatrix

für die im QR-Verfahren erzeugten Matrix  $A_t$  gilt:

$$\{\lim_{t \rightarrow \infty} a_{j,j}^{(t)} | j = 1, \dots, n\} = \{\lambda_1, \dots, \lambda_n\}$$