

# Inhaltsverzeichnis

<b>1</b>	<b>Norm und Skalarprodukt</b>	<b>3</b>
1.1	Norm . . . . .	3
1.2	Skalarprodukt . . . . .	3
1.2.1	Vom Skalarprodukt induzierte Norm . . . . .	3
1.2.2	Cauchy-Schwarzche Ungleichung . . . . .	3
<b>2</b>	<b>Symmetrische, positiv definite Matrix</b>	<b>4</b>
2.1	Cholesky-Zerlegung $A = GG^t$ . . . . .	4
2.2	[?] diagonaldominant und alle $a_{ii} \geq 0$ . . . . .	4
2.3	Eigenwerte . . . . .	4
2.4	Eigenvektor . . . . .	4
<b>3</b>	<b>Matrixnormen</b>	<b>5</b>
3.1	Natürliche Matrixnorm . . . . .	5
3.2	Verträglichkeit . . . . .	5
3.3	Zeilensummennorm . . . . .	5
3.4	Spaltensummennorm . . . . .	5
3.5	Spektralnorm . . . . .	5
<b>4</b>	<b>Spektralradius, Konditionszahl einer Matrix</b>	<b>6</b>
4.1	Spektralradius $\varphi$ . . . . .	6
4.2	Konditionszahl einer Matrix A . . . . .	6
4.3	Sonderfall symmetrisch, positiv definite Matrix . . . . .	6
<b>5</b>	<b>Ähnlichkeitstransformation, Invarianz der Eigenwerte</b>	<b>7</b>
5.1	Reduktionsmethoden . . . . .	7
<b>6</b>	<b>Gleitkommazahlen</b>	<b>8</b>
6.1	Gleitkommazahl (normalisiert) . . . . .	8
6.2	Gleitkommagitter . . . . .	8
6.3	Maschinengenauigkeit eps . . . . .	8
6.4	Rundungsfehler . . . . .	8
<b>7</b>	<b>Darstellung des Interpolationsfehlers</b>	<b>9</b>
7.1	Fehler I . . . . .	9
7.2	Fehler II . . . . .	9
<b>8</b>	<b>Konditionierung einer numerischen Aufgabe, Konditionszahlen <math>k_{ij}</math></b>	<b>10</b>
8.1	numerische Aufgabe . . . . .	10

8.2	Konditionszahl (relativ)	10
<b>9</b>	<b>Stabilität eines Algorithmus</b>	<b>11</b>
9.1	stabiler Algorithmus	11
<b>10</b>	<b>Auslöschung</b>	<b>12</b>
<b>11</b>	<b>Horner-Schema*</b>	<b>13</b>
11.1	Code	13
11.2	Auswertung	13
<b>12</b>	<b>Interpolation und Approximation</b>	<b>14</b>
12.1	Grundproblem	14
12.2	Aufgabenstellung	14
12.3	Interpolation	14
12.4	Approximation	14
<b>13</b>	<b>Lagransche Interpolationsaufgabe</b>	<b>15</b>
13.1	Aufgabe	15
13.2	Eindeutigkeit + Existenz	15
13.3	Lagransche Basispolynome	15
13.4	Eigenschaften	15
13.5	Lagransche Darstellung	15
<b>14</b>	<b>Newtonsche Basispolynome, dividierte Differenzen</b>	<b>16</b>
14.1	Newton-Polynome	16
14.1.1	Auswertung	16
14.1.2	Vorteil	16
14.2	Newtonsche Darstellung	16
14.3	Dividierte Differenzen*	16
<b>15</b>	<b>Nevillsche Darstellung</b>	<b>17</b>
15.1	Schema	17

# 1 Norm und Skalarprodukt

## 1.1 Norm

Definitheit:  $||x|| = 0 \Rightarrow x = 0$

absolute Homogenität:  $||\alpha x|| = |\alpha| \cdot ||x||$

Dreiecksungleichung:  $||x + y|| \leq ||x|| + ||y||$

## 1.2 Skalarprodukt

$$|x + y, z| = |x, z| + |y, z|$$

$$|x, y + z| = |x, y| + |x, z|$$

TODO: Klammer

$$\langle \lambda x, y \rangle = \lambda \langle x, y \rangle$$

$$\langle x, \lambda y \rangle = \lambda \langle x, y \rangle$$

$$|x, y| = |y, x|$$

$$\langle x, x \rangle \geq 0$$

$$\langle x, x \rangle = 0 \Rightarrow x = 0$$

### 1.2.1 Vom Skalarprodukt induzierte Norm

$$||x|| = \sqrt{\langle x, x \rangle}$$

### 1.2.2 Cauchy-Schwarzche Ungleichung

$$|\langle x, y \rangle| \leq ||x|| \cdot ||y||$$

## 2 Symmetrische, positiv definite Matrix

TODO: Matrizen

insbesonders: Diagonalmatrizen, Einheitsmatrizen

positiv definit:  $x^t A x > 0$  (beliebige Matrix)

alle EW  $\geq 0$  (symmetrische Matrix)

alle Haupt[TODO: ?]  $\geq 0$  (symmetrische Matrix)

TODO: Matrix  $\Rightarrow$  3 Hauptminoren[?] =  $\det(a)$ ,  $\det(\text{TODO: Matrix})$ ,  
 $\det(\text{TODO: Matrix})$

### 2.1 Cholesky-Zerlegung $A = G G^t$

G unter der Matrix, invertierbar (symmetrische Matrix)

### 2.2 [?] diagonaldominant und alle $a_{ii} \geq 0$

(symmetrische Matrix)

### 2.3 Eigenwerte

$$\det(\lambda E_n - A) = 0$$

### 2.4 Eigenvektor

$$f(v) = \lambda v$$

### 3 Matrixnormen

#### 3.1 Natürliche Matrixnorm

$$\|A\|_{\infty} := \max_{x \neq 0} \frac{\|Ax\|_{\infty}}{\|x\|_{\infty}} = \max_{\|x\|_{\infty}=1} \|Ax\|_{\infty}$$

$$\|A\| = 0 \Rightarrow A = 0, \|\lambda A\| = |\lambda| \|A\|, \|A + B\| \leq \|A\| + \|B\|, \|A * B\| \leq \|A\| * \|B\|$$

#### 3.2 Verträglichkeit

$$\|Ax\| \leq \|A\| * \|x\|$$

#### 3.3 Zeilensummennorm

= natürliche Matrixnorm

$$\|A\|_{\infty} = \max_{\|x\|_{\infty}=1} \|Ax\|_{\infty} = \max_{i=1, \dots, m} \sum_{j=1}^n |a_{ij}|$$

$$A = \begin{pmatrix} 1 & -2 & -3 \\ 2 & 3 & -1 \end{pmatrix} : \text{Matrix} \quad \|A\|_{\infty} = \max\{1+|-2|+|-3|, |2|+|3|+|-1|\} = \max\{6, 6\} = 6$$

#### 3.4 Spaltensummennorm

$$\|A\|_1 := \max_{x \neq 0} \frac{\|Ax\|_1}{\|x\|_1} = \max_{\|x\|_1=1} \|Ax\|_1 = \max_{j=1, \dots, n} \sum_{i=1}^m |a_{ij}|$$

$$A = \begin{pmatrix} 1 & -2 & -3 \\ 2 & 3 & -1 \end{pmatrix} : \text{Matrix} \quad \|A\|_1 = \max\{|1|+|2|, |-2|+|3|, |-3|+|-1|\} = \max\{3, 5, 4\} = 5$$

$$\|A^t\|_1 = \|A\|_{\infty}$$

#### 3.5 Spektralnorm

$$\|A\|_2 := \max_{\|x\|_2=1} \|Ax\|_2 = \max_{x \neq 0} \frac{\|Ax\|_2}{\|x\|_2} = \max_{\|x\|_2=1} \langle Ax, Ax \rangle = \max_{\|x\|_2=1} \langle A^t A x, x \rangle = \max \sqrt{|\lambda|}, \lambda * \text{EW von } A^t A$$

$$A = \begin{pmatrix} 1 & -2 & -3 \\ 2 & 3 & -1 \end{pmatrix} : \text{Matrix}, A^t A = \begin{pmatrix} 10 & -1 \\ -1 & 14 \end{pmatrix} : \text{Matrix} \quad \det(\mu E_n - A^t A) = 0 \Leftrightarrow \mu_{1,2} = 16, 1$$

$$\|A\|_2 = \sqrt{\max(\mu_1, \mu_2)} = \sqrt{\mu_1} = \sqrt{16} = 4$$

## 4 Spektralradius, Konditionszahl einer Matrix

### 4.1 Spektralradius $\varphi$

$\varphi(A) = \max : 1 \leq i \leq n |\lambda_i(A)| = \text{spr}(A)$  der betragsmäßig größte Eigenwert von A

$\|A\| \geq |\lambda|$  (für jede Matrixnorm, die mit einer Vektornorm verträglich ist)

### 4.2 Konditionszahl einer Matrix A

$$\text{cond}(A) = \|A\| \|A^{-1}\|$$

### 4.3 Sonderfall symmetrisch, positiv definite Matrix

$$\text{cond}(A) = \frac{\lambda_{\max}}{\lambda_{\min}}$$

## 5 Ähnlichkeitstransformation, Invarianz der Eigenwerte

$$y = Ax$$

$$\bar{x} = Cx, \bar{y} = Cy \quad (\det C \neq 0), C \in GL$$

$$y = Ax \Rightarrow C^{-1}\bar{y} = AC^{-1}\bar{x} \Rightarrow \bar{y} = CAC^{-1}\bar{x} \Rightarrow \bar{y}\bar{A}\bar{x}$$

$$\bar{A} = CAC^{-1} \Rightarrow \bar{A} \sim A$$

$$\lambda EW, vEV \text{ zu } A$$

$$\Rightarrow Av = C^{-1}\bar{A}Cv = \lambda v$$

$\Rightarrow \bar{A}$  und  $A$  haben dieselben Eigenwerte, algebraisch und geometrische Vielfalten stimmen überein (Invarianz der Eigenwerte)

### 5.1 Reduktionsmethoden

A durch Ähnlichkeitstransformationen

$$A = A^{(0)} = T_1^{-1}A^{-1}T_1 = Q \dots = T_i^{-1}A^{(i)}T_i = \dots$$

auf Form bringen, für welche EW und EV leicht zu berechnen sind (z.B. Jordan-Normalform)

## 6 Gleitkommazahlen, Gleitkommagitter, Maschinengenauigkeit, Rundungsfehler

### 6.1 Gleitkommazahl (normalisiert)

$$b \in \mathbb{N}, b \geq 2, x \in \mathbb{R}$$

$$x = \pm m * b^{\pm e}$$

$$\text{Mantisse: } m = m_1 b^{-1} + m_2 b^{-2} + \dots \in \mathbb{R}$$

$$\text{Exponent: } e = e_{s-1} b^{s-1} + \dots + e_0 b^0 \in \mathbb{N}$$

für  $x \neq 0$  eindeutig

### 6.2 Gleitkommagitter

$$A = A(b^1, r^2, s^3) \quad \text{größte Darstellbare Zahl: } (1 - b^{-r}) * b^{b^s-1}$$

$$(b = 10) : 0,314 * 10^1 = 3,14$$

$$0,123 * 10^6 = 123.000$$

Beispiel: konvertiere von Basis 8 zu Basis 10:

$$x = (0,5731 * 10^5)_8 \in A(8, 5, 1)$$

$$x = (5 * 8^{-1} + 7 * 8^{-2} + 3 * 8^{-3} + 1 * 8^{-4}) * 8^5$$

$$x = 5 * 8^4 + 7 * 8^3 + 3 * 8^2 + 1 * 8^1 = 24.264 * 10^0$$

### 6.3 Maschinengenauigkeit eps

$$eps = \frac{1}{2} b^{-r+1}, IEEE : eps = \frac{1}{2} * 2^{-52} \approx 10^{-16}$$

### 6.4 Rundungsfehler

$$\text{absolut : } |x - rd(x)| \leq \frac{1}{2} b^{-r} b^e$$

$$\text{relativ : } \left| \frac{x - rd(x)}{x} \right| \leq \frac{1}{2} b^{-r+1} = eps$$

---

<sup>1</sup>Basis

<sup>2</sup>Mantissenlänge

<sup>3</sup>Exponentenlänge



## 7 Darstellung des Interpolationsfehlers

### 7.1 Fehler I

$$f \in C^{n+1}[a, b], \forall x \in [a, b] \exists \xi_x \in (\overline{x_0, \dots, x_n, x})^4, s.d.$$

$$f(x) - p(x) = \frac{f^{(n+1)}(\xi_x)}{(n+1)!} \prod_{j=0}^n (x - x_j)$$

### 7.2 Fehler II

$$f \in C^{n+1}[a, b], \forall x \in [a, b] \setminus \{x_0, \dots, x_n\} \text{ gilt :}$$

$$f(x) - p(x) = f[x_0, \dots, x_n, x] \prod_{j=0}^n (x - x_j)$$

$$\text{mit } f[x_i, \dots, x_{i+k}] = y[x_i, \dots, x_{i+k}]$$

$$\text{und } f[x_0, \dots, x_n, x] = \int_0^1 \int_0^{t_1} \dots \int_0^{t_n} f^{n+1}(x_0 + t_1(x_1 - x_0) + \dots + t_n(x_n - x_{n-1} + t(x - x_n))) dt dt_n \dots dt_1$$

$$\text{für } x_0 = x_1 = \dots = x_n :$$

$$f[x_0, \dots, x_n] = \frac{1}{n!} f^{(n)}(x_0)$$

$$\frac{f^{(n+1)}(\xi_x)}{(n+1)!} \prod_{j=0}^n (x - x_j) = f(x) - p(x) = f[x_0, \dots, x_n, x] \prod_{j=0}^n (x - x_j)$$

$$\Rightarrow f[x_0, \dots, x_n, x] = \frac{f^{(n+1)}(\xi_x)}{(n+1)!}$$

---

<sup>4</sup>kleinstes Intervall, das alle  $x_i$  enthält

## 8 Konditionierung einer numerischen Aufgabe, Konditionszahlen $k_{ij}$

### 8.1 numerische Aufgabe

$x_j \in \mathbb{R}$  mit  $f(x_1, \dots, x_m) \Rightarrow y_i = f_i(x_j)$   
fehlerhafte Eingangsgrößen  $x_i + \Delta y_i$   
 $|\Delta y_i|$  ist der absolute Fehler,  $|\frac{\Delta y_i}{y_i}|$  ist der relative Fehler

### 8.2 Konditionszahl (relativ)

$$k_{ij}(x) = \frac{\partial f_i}{\partial x_j}(x) \frac{\Delta x_j}{x_j}$$
$$\frac{\Delta y_i}{y_i} = \sum_{j=1}^m k_{ij}(x) \frac{\Delta x_j}{x_j}$$

$|k_{ij}(x)| \gg 1 \Rightarrow$  schlecht konditioniert  
 $|k_{ij}(x)| \ll 1 \Rightarrow$  gut konditioniert, ohne Fehlerverstärkung  
 $|k_{ij}(x)| > 1 \Rightarrow$  Fehlerverstärkung  
 $|k_{ij}(x)| < 1 \Rightarrow$  Fehlerdämpfung

## 9 Stabilität eines Algorithmus

### 9.1 stabiler Algorithmus

akkumulierte Fehler der Rechnung (Rundungsfehler, Auswertungsfehler, etc.) übersteigen den unvermeidbaren Problemfehler der Konditionierung der Aufgabe nicht. Aka Trotz Ungenauigkeiten bei den Eingabe Variablen erhalten wir fast sehr genaue Ergebnisse.

## 10 Auslöschung

Verlust von Genauigkeit bei der Subtraktion von Zahlen mit gleichem Vorzeichen

TODO: bei bedarf ein Beispiel

## 11 Horner-Schema\*

$$p(x) = a_0 + x(\dots + x(a_{n-1} + a_n x)\dots)$$

### 11.1 Code

```
def horner(Ac5, Ax6, n7, x8): // 9
    y = 0.0
    for i in reversed range(n):
        y = y * (x - Ax[i]) + Ac[i]
    return y
```

Immer Horner-Schema zur Auswertung von Polynomen verwenden.

### 11.2 Auswertung

TODO: subsection

---

<sup>5</sup>Vektor mit Koeffizienten

<sup>6</sup>Stützstellen

<sup>7</sup>Anzahl der Stützstellen

<sup>8</sup>Auswertungspunkt

<sup>9</sup>wobei Ac und Ax np Arrays sind, n ein int und x ein double

## 12 Interpolation und Approximation

### 12.1 Grundproblem

Darstellung und Auswertung von Funktionen

### 12.2 Aufgabenstellung

$f(x)$  nur auf diskreter Menge von Argumenten  $x_0, \dots, x_n$  bekannt und soll rekonstruiert werden

analytisch gegebene Funktion soll auf Reelwerte dargestellt werden, damit jederzeit Werte zu beliebigen  $x$  berechnet werden können.

Einfach konstruierte Funktionen in Klassen  $P$ :

Polynome:  $p(x) = a_0 + a_1x + a_2x^2 + \dots + a_nx^n$

rationale Funktion:  $r(x) = \frac{a_0 + a_1x + \dots + a_nx^n}{b_0 + b_1x + \dots + b_mx^m}$

trigonometrische Funktion:  $t(x) = \frac{1}{2}a_0 + \sum_{k=1}^n (a_k \cos(kx) + b_k \sin(kx))$

Exponentialsummen:  $e(x) = \sum_{k=1}^n a_k \exp(b_k x)$

### 12.3 Interpolation

Zuordnung von  $g \in P$  zu  $f$  durch Fixieren von Funktionswerten

$$g(x_i) = y_i = f(x_i), i = 0, \dots, n$$

### 12.4 Approximation

$g \in P$  beste Darstellung, z.B.

$$\max_{a \leq x \leq b} |f(x) - g(x)| \text{ minimal}$$

$$\left( \int_a^b |f(x) - g(x)|^2 dx \right)^{\frac{1}{2}} \text{ minimal}$$

## 13 Lagransche Interpolationsaufgabe

### 13.1 Aufgabe

Finde zu  $n + 1$  verschiedene Stützstellen/Knoten  $x_0, \dots, x_n \in \mathbb{R}$  und  $y_0, \dots, y_n \in \mathbb{R}$  mit  $p(x_i) = y_i$

### 13.2 Eindeutigkeit + Existenz

Die Lagransche Interpolationsaufgabe ist eindeutig lösbar

TODO: bei bedarf Beweis rein kopieren den Ich nicht verstanden hab

### 13.3 Lagransche Basispolynome

$$L_i^{(n)}(x) = \prod_{j=0, j \neq i}^n \frac{x - x_j}{x_i - x_j} \in P_n, i = 0, \dots, n$$

### 13.4 Eigenschaften

ortogonal: es gilt  $L_i^{(n)}(x_k) = d_{ik} = \begin{cases} 1 & i = k \\ 0 & \text{sonst} \end{cases}$   
bilden Basis von  $P_n$   
haben Grad  $n$

### 13.5 Lagransche Darstellung

$$p(x) = \sum_{i=0}^n y_i L_i^{(n)}(x) \in P_n \text{ mit } p(x_j) = y_j$$

Nachteil: Bei Hinzunahme von  $(x_{n+1}, y_{n+1})$  ändert sich das Basispolynom komplett

TODO: Beispiel

## 14 Newtonsche Basispolynome, dividierte Differenzen

### 14.1 Newton-Polynome

$$N_0(x) = 1, N_i(x) = \prod_{j=0}^{i-1} (x - x_j) \text{ mit } p(x) = \sum_{i=0}^n a_i N_i(x)$$

#### 14.1.1 Auswertung

$$\begin{aligned} y_0 &= p(x_0) = a_0 \\ y_1 &= p(x_1) = a_0 + a_1 * (x_1 - x_0) \\ &\vdots \\ y_n &= p(x_n) = a_0 + a_1(x_1 - x_0) + \dots + a_n(x_n - x_0) * \dots * (x_n - x_{n-1}) \end{aligned}$$

#### 14.1.2 Vorteil

Bei Hinzunahme von  $(x_{n+1}, y_{n+1})$  muss nur eine neue Rechnung durchgeführt werden, und nicht das gesamte Polynom neu berechnet werden

TODO: Beispiel

### 14.2 Newtonsche Darstellung(stabile Variante)

$$p(x) = \sum_{i=0}^n y[x_0, \dots, x_i] N_i(x)$$

### 14.3 Dividierte Differenzen\*

$$y[x_i, \dots, x_{k+1}] = \frac{y[x_{i+1}, \dots, x_{k+1}] - y[x_i, \dots, x_{k-1}]}{x_{i+k} - x_i} \text{ mit } k = 1, \dots, j \text{ und } i = k - j$$

für beliebige  $[?] \sigma : 0, \dots, n \rightarrow 0, \dots, n$  gilt  $y[\tilde{x}_0, \dots, \tilde{x}_n] = y[x_0, \dots, x_n]$



## 15 Nevillsche Darstellung

$$p_{jj}(x) = y_j \quad j = 0, \dots, n \quad k = 1, \dots, j \quad i = k - j$$

$$p_{i,i+k}(x) = p_{i,i+k-1}(x) + (x - x_i) \frac{p_{i+1,i+k}(x) - p_{i,i+k-1}(x)}{x_{i+k} - x_i}$$

### 15.1 Schema

$$\begin{array}{ccccccc} x & k=0 & k=2 & \dots & k=n-1 & k=n \\ x_0 & y_0 & \Gamma \rightarrow & p_{0,1} & \dots & p_{0,n-1} & p_{0,n} \end{array}$$